

Einführung in MLOps

15 FTI PIPELINE ARCHITEKTUR

Tobias Mérinat

teaching2025@fsck.ch


Lucerne University of
Applied Sciences and Arts

**HOCHSCHULE
LUZERN**

DEPARTMENT OF INFORMATION TECHNOLOGY
Lucerne University of Applied Sciences and Arts
6343 Rotkreuz, Switzerland


22. und 23. August 2025

Architektur Overview 1/2




Quelle: Google

Architektur Overview 2/2



Quelle: Databricks


- Notebook und ein trainiertes Modell $\neq$ ML System
- Erst, wenn mit neuen Daten predicted wird
- Für ein System benötigen wir Pipelines



Quelle: Hopsworks

Erster Versuch: Monolithische Pipeline


- Alles in einer Pipeline
- Ein Toggle wählt *Training* oder *Inferenz*
- Vorteil: Featureberechnung erfolgt nur einmal
- Nachteil: Keine Modularität, skaliert schlecht da eine Technologie für alles



Quelle: Hopsworks

Training und Inferenz separieren


- Natürlicher Schritt: Training und Inferenz separieren
- Vorteil: Mehr Modularisierung
- Nachteil: Feature Engineering muss dupliziert werden




Quelle: Hopsworks

FTI or 3 Pipeline Architektur

- **Feature Pipeline:** Input = Rohdaten, output = Features (und Labels)
- **Training Pipeline:** Input = Features und Labels, output = trainiertes Modell
- **Inference Pipeline:** Input = Aktuelle Features+Modell, output = prediction






- Technologie-offen
 - Python/Pandas für Training, Spark/dbt für Feature-Berechnung
 - Nicht abhängig von einer bestimmten ML Registry oder eines Feature Stores
 - Cloud oder on-premise möglich
- Einfach ausbaubar
 - Feature Store / Model Registry von einfacher Fileablage bis Full-Featured Produkt
- Modular / Reusable / Separat optimier- und skalierbar

F Pipeline vs. Experimentierphase

- F vor T vor I nicht effizient
- Experiment first, prove that it works or fail fast



- Mehr zu Monitoring später
- Es braucht jedoch noch einen vierten Typ von Pipeline: Die Monitoring-Pipeline
- Nicht das ganze Monitoring kann und sollte in den FTI Pipelines gemacht werden
 - Referenzdaten nur bei Monitoring benötigt
 - Gewisse Datenmenge notwendig -> funktioniert nicht innerhalb von Streaming Feature Pipelines
 - Wenn Natural Labels stark verzögert -> funktioniert nicht in I Pipeline