

Einführung in MLOps

17 MODEL DRIFT

Tobias Mérinat

teaching2025@fsck.ch

Lucerne University of
Applied Sciences and Arts

**HOCHSCHULE
LUZERN**

DEPARTMENT OF INFORMATION TECHNOLOGY
Lucerne University of Applied Sciences and Arts
6343 Rotkreuz, Switzerland

22. und 23. August 2025

Software ohne ML faillt aufgrund von

- Fehler in der Programmlogik (Bug, falsche Requirements)
- Fehlern in Up- oder Downstream-Systemen (Bugs, Interface-Changes)
- Infrastrukturproblemen (Downtime, Fehlkonfiguration, Netzwerkproblem).

Software faillt

- mit einer Exception
- still

Software mit ML kann auf eine zusätzliche Art failen:

- System läuft (gleich wie bisher) korrekt (keine der obigen Ursachen)
- aber die Performance nimmt trotzdem ab

- Grundannahme in Machine Learning: *Unseen Data* kommt aus derselben (stationären) Verteilung wie die Trainingsdaten
- Modellentwicklung:
 - fixes Trainingsset
 - korrekte Cross Validation
- Modell = Snapshot der Wirklichkeit zum Zeitpunkt des Trainings
- Die Welt ist aber nicht statisch, sie ändert sich, womit sich auch die Inputdaten für ein Modell ändern können

- **Model Drift:** Der Umstand, dass die Vorhersagequalität eines ML- Modells im Laufe der Zeit schlechter werden kann, obwohl sich an dem Modell an sich nichts verändert.
- Synonym: *shift* oder kurz *drift*
- *Model Drift* ist ein unglücklich gewählter Begriff, da sich das Model nicht verändert, sondern dessen Inputdaten
- **Skew:** Unterschied zweier Verteilungen, speziell *Training-Serving-Skew*.
- *Skew* ist der Unterschied, *Drift* die (schleichend) zunehmende Abweichung
- Grundsätzlich: Wenn sich die Verteilung der Daten zum Zeitpunkt der Inferenz von derer zum Zeitpunkt der Trainings abweicht

Drift kann ein grosses Problem darstellen, wenn wir ML in der realen Welt einsetzen, in der Daten oft dynamisch und ständig im Wandel sind.

- X sind die Inputs eines Modells, Y sind dessen Outputs
- In Supervised Learning kommen die Trainingsdaten aus der gemeinsamen Wahrscheinlichkeitsverteilung $P(X, Y)$.
- Modelliert wird $P(Y|X)$
- Für die gemeinsame Verteilung gilt
 - $P(X, Y) = P(Y|X)P(X)$
 - $P(X, Y) = P(X|Y)P(Y)$
- Dabei ist
 - $P(Y|X)$ die bedingte Wahrscheinlichkeit eines Outputs, gegeben den Input
 - $P(X)$ die Wahrscheinlichkeit der Inputs
 - $P(Y)$ die Wahrscheinlichkeit der Outputs

Drift wird in drei Haupt-Kategorien aufgeteilt, es können Mischformen auftreten:

- **Covariate Shift** $P(X)$ ändert, aber $P(Y|X)$ bleibt gleich
- **Label Shift** $P(Y)$ ändert, aber $P(X|Y)$ bleibt gleich
- **Concept drift** $P(Y|X)$ ändert, aber $P(X)$ bleibt gleich

Covariate Shift: $P(X)$ ändert, $P(Y|X)$ bleibt gleich


- Die Inferenz-Daten sind anders als die Trainingsdaten
- Kann während Trainingsphase eingeführt werden, z.B. durch Selection Bias
 - Oversampling eines Imbalanced Datensets
 - Active Learning
- Oft ausgelöst durch eine substantielle Veränderung der Umgebung oder der Art, wie ein Produkt verwendet wird.
 - App mit Feature *Alter* wird von einer anderen Altersgruppe verwendet, als durch die Trainingsdaten gegeben war
 - oder in einem anderen Land
 - oder durch andere Sensoren, neuere und höherauflösende Kameras, oder mit Noise im Hintergrund, während Trainingsdaten in einem isolierten Raum aufgezeichnet wurden.

Label Shift: $P(Y)$ ändert, $P(X|Y)$ bleibt gleich

- Auch als *prior shift* oder *prior probability shift* oder *target shift* bezeichnet
- Verteilung der Zielvariablen ändert sich, aber für ein gegebenes Label bleibt die Input-Verteilung gleich
- Covariate Shift and Label Shift treten oft, aber nicht immer, gemeinsam auf

Concept Drift: $P(Y|X)$ ändert, $P(X)$ bleibt gleich


- Auch als *posterior shift* bezeichnet
- *Same input, different output*
- Saisonale Effekte spielen oft eine Rolle. Höhere Preise am Wochendende wie unter der Woche.
- Kann schleichend oder plötzlich kommen



- Inputdaten und Modellperformance muss überwacht werden
- Modelle müssen periodisch neu trainiert werden

Wir können vier Stufen von Drift Monitoring unterscheiden

- 1 Raw Data
- 2 Features
- 3 Predictions
- 4 Metriken



* if natural labels available

Metriken (Natural Labels)

- Um Metriken direkt zu messen, benötigen wir *Natural Labels*
- Wir speichern die Predictions aus der Inferenz und berechnen und prüfen periodisch
- Je schneller die Labels anfallen, desto schneller können wir reagieren
- Neben Natural Labels sollte aber auch jegliches anderes Feedback geloggt werden, welches als Proxy für ein Natural Label dienen könnte.
 - Clicks auf Recommendations
 - Bookmarks
 - Upvotes
 - Shares
 - Likes
 - Klick auf *skip* bzw. Abbruch (Spotify, Youtube)
 - Nutzungsdauer
 - . . .
- Entweder können natural labels abgeleitet werden oder sonst verwenden, um auftretende Veränderungen zu erkennen

- Haben wir keine Ground Truth, vergleichen wir Verteilungen aktueller Daten mit Verteilungen von Referenzdaten
 - 1 Wir bilden Windows der Inference Requests
 - 2 berechnen die Verteilung eines Window
 - 3 verwenden eine Metrik, die berechnete Verteilung mit einem Referenzdatensatz zu vergleichen
 - 4 speichern die berechneten Metriken als Zeitreihe, um Trends zu erkennen
- Features: einfacher, weil Schema; Möglichkeit, neben Endwerten auch Zwischenstufen zu monitoren
- Rohdaten: gleiches Vorgehen, aufgrund oft fehlender Struktur jedoch etwas schwieriger
- Predictions: Fehlt ein Natural Label, kann man auch Veränderungen an der Verteilung der Predictions messen

How can data drift in text manifest itself? A few Examples:

- Words change their meaning: The word *sick* slowly changes from a negative to a positive sentiment
- New popular words, brands, abbreviations or memes emerge: *tl;dr*, *LOL*, *BRB*, *GDPR*, *tiktok*, *deepseek*, . . .
- New ways of writing, e.g. mixing languages, *Spanglish*: *I'm so tired lah, trabajo all day sia*
- Twitter removes 140 character limit, texts become longer

Drift Metrics for Text Data 1/2

■ Text statistics

- Average / min / max # of chars / words / sentences / paragraphs

■ Text health

- OOV word percentage (based on given vocab)
- Non-Letter character percentage

■ Text content (avg number of matches / percentage of texts with at least one)

- special markers (hashtags, @mentions, emojis, links)
- special matches (begins with, contains, regex, . . .)
- trigger words

	current	reference
count	4929	4805
missing	71 (0.014%)	195 (0.039%)
Text Length min	0.0	0.0
Text Length mean	311.571	290.544
Text Length max	508.0	504.0
OOV % min	0.0	0.0
OOV % mean	5.853	5.378
OOV % max	40.0	42.857
Non Letter Character % min	0.0	0.0
Non Letter Character % mean	3.629	3.802
Non Letter Character % max	12.17	16.667

Source: Evidently

- Classifier-based
 - average sentiment score
 - counts by classes
 - similarity scores to reference
- Embeddings Drift (with or without prior dimensionality reduction such as PCA or T-SNE)
 - Distance metrics (euclidean, cosine, . . .)
 - Classifier model
 - Share of drifted embedding components (treat embedding as a table)

Which metric to choose?

- How representative is it for the use case?
- How easy is it to interpret the drift score?
- How stable are the results? How much variance is there?
- How fast are the computations?
- How fragile is the method?

Beeinträchtigt der Drift die Modell-Performance zu stark, muss das Modell neu trainiert werden.

- Nur mit frischen Daten trainieren (wenn notwendig labeln)
- Mit alten und neuen Daten trainieren
- Testen, welche alten Daten noch gut sind und behalten werden können
- Evaluieren und mit altem Modell vergleichen

- Generell möglichst viel monitoren, und laufend anpassen
- Brainstormen, was alles schief gehen könnte, dann entsprechende Metriken definieren
 - Operative Metriken: Memory, CPU-Auslastung, Latenz, Throughput, Server Load
 - Statistical Health der Eingangsdaten
 - Anzahl NaNs, Average Image Brightness
 - Statistical Health der Outputs
 - Verteilung, Anzahl Nulls, Anzahl True in a row
 - Benutzer-Verhalten: CTR, mit Content verbrachte Zeit, Likes, Shares, Upvotes, . . .
 - Performance auf einem speziell wichtigen Daten-Subset (als separate Metrik)

- Datentypen
- Daten-Ranges (min, max oder Werte-Set)
- Regexps
- Not Null
- Key Constraints