

Einführung in MLOps

21 DATA VALIDATION

Tobias Mérinat

teaching2025@fsck.ch

Lucerne University of
Applied Sciences and Arts

**HOCHSCHULE
LUZERN**

DEPARTMENT OF INFORMATION TECHNOLOGY
Lucerne University of Applied Sciences and Arts
6343 Rotkreuz, Switzerland

22. und 23. August 2025

- Validierung des Schemas der Input-Daten
- Rein syntaktisch
 - nicht semantisch
 - nicht statistisch

- Eine der häufigsten Ursachen von Fehlern in Datenpipelines
- Ziele
 - frühzeitiges Erkennen von Datenproblemen
 - möglichst aussagekräftige Fehlermeldungen

- Anzahl Spalten, Spalten-Namen
- Spalten-Reihenfolge
- Datentypen
- Daten-Ranges (min, max oder Werte-Set)
- Regexps
- Not Null
- Key Constraints

■ PyDantic

- Verbreitet, sehr Pythonic
- Fokus auf Klassen, nicht DataFrames
- Nicht gut geeignet für Data Pipelines

■ Pandera

- Unterstützt Pandas, PySpark, Polars
- Relativ flache Lernkurve

■ Great Expectations

- DeFacto Tool für produktive Datenvalidierung
- On-Premise und Cloud Lösung
- Komplettes System mit Reports, Profiling, Documentation Generation und Tool-Integration (Airflow, dbt, Spark, SQL Datenbanken, Slack, . . .)
- Steile Lernkurve